

Министерство науки и высшего образования РФ

Федеральное государственное автономное образовательное учреждение
высшего образования «Казанский (Приволжский) федеральный университет»

**ИНСТИТУТ ВЫЧИСЛИТЕЛЬНОЙ МАТЕМАТИКИ
И ИНФОРМАЦИОННЫХ ТЕХНОЛОГИЙ**

**КАФЕДРА ПРИКЛАДНОЙ МАТЕМАТИКИ
И ИСКУССТВЕННОГО ИНТЕЛЛЕКТА**

Направление: 01.03.04 – Прикладная математика

Профиль: Прикладная математика

ОТЧЁТ

по лабораторной работе

«Многослойный персептрон»

Выполнил: студент группы 09-322

Каримов А.И.

Проверил: _____

Казань, 2026

Содержание

1	Введение	2
2	Анализ и предобработка данных	2
3	Математическое обоснование	2
3.1	Архитектура сети	2
3.2	Функции активации	3
3.3	Функция потерь и обратное распространение	3
3.4	Оценка модели	3
4	Описание программы	3
5	Результаты	4
6	Заключение	4

1 Введение

Целью данного проекта является реализация алгоритма многослойного персептрона (MLP) с нуля на языке Python для решения задачи бинарной классификации. В ходе работы были применены знания линейной алгебры и математического анализа (вычисление производных сложной функции) для реализации прямого и обратного распространения ошибки, а также градиентного спуска.

2 Анализ и предобработка данных

Набор данных `data.csv` содержит 32 столбца:

- `id`: уникальный идентификатор образца (удален, так как не несет семантической нагрузки).
- `diagnosis`: целевая переменная (М – злокачественная, В – доброкачественная).
- 30 числовых признаков, описывающих характеристики ядра клетки (радиус, текстура, периметр, площадь, гладкость и т.д.)

Предобработка:

1. Кодирование меток: $V \rightarrow 0$, $M \rightarrow 1$.
2. Стандартизация признаков (Z-score normalization):

$$x' = \frac{x - \mu}{\sigma} \quad (1)$$

где μ – среднее, σ – стандартное отклонение. Это необходимо для стабильной работы градиентного спуска.

3. Разделение данных: 80% на обучение, 20% на проверку с фиксированным `seed=42` для воспроизводимости.

3 Математическое обоснование

3.1 Архитектура сети

Модель содержит два скрытых слоя. Для слоя l прямой проход вычисляется как:

$$Z^{[l]} = A^{[l-1]}W^{[l]} + b^{[l]} \quad (2)$$

где $A^{[0]} = X$ (входные данные).

3.2 Функции активации

Для скрытых слоев используется функция **ReLU**:

$$\text{ReLU}(z) = \max(0, z), \quad \frac{\partial \text{ReLU}}{\partial z} = \begin{cases} 1, & \text{if } z > 0 \\ 0, & \text{if } z \leq 0 \end{cases} \quad (3)$$

На выходном слое используется функция **Softmax** для получения вероятностного распределения по двум классам:

$$\sigma(z)_i = \frac{e^{z_i}}{\sum_j e^{z_j}} \quad (4)$$

3.3 Функция потерь и обратное распространение

Для обучения используется категориальная кросс-энтропия (совместимая с Softmax):

$$\mathcal{L} = -\frac{1}{m} \sum_{i=1}^m \sum_{k=1}^2 y_{ik} \log(\hat{y}_{ik}) \quad (5)$$

Производная функции потерь по выходу слоя Softmax имеет элегантный вид: $\frac{\partial \mathcal{L}}{\partial Z^{[L]}} = \hat{Y} - Y$.

Далее ошибка распространяется назад по сети:

$$dW^{[l]} = \frac{1}{m} (A^{[l-1]})^T dZ^{[l]} \quad (6)$$

$$db^{[l]} = \frac{1}{m} \sum dZ^{[l]} \quad (7)$$

$$dZ^{[l]} = dZ^{[l+1]} (W^{[l+1]})^T \odot \text{ReLU}'(Z^{[l]}) \quad (8)$$

Обновление весов осуществляется с помощью градиентного спуска: $W^{[l]} = W^{[l]} - \alpha dW^{[l]}$.

3.4 Оценка модели

Согласно заданию, итоговая оценка производится с помощью **бинарной кросс-энтропии** (BCE) для вероятности положительного класса (М):

$$\text{BCE} = -\frac{1}{m} \sum_{i=1}^m [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)] \quad (9)$$

где $\hat{p}_i$ – вероятность класса М, предсказанная сетью.

4 Описание программы

Проект модульный и состоит из трех основных скриптов:

- `split_data.py`: отвечает за загрузку `data.csv`, очистку, стандартизацию и сохранение массивов в формате `.npz`.

- `train.py`: содержит класс `MultilayerPerceptron`. Реализует методы `forward`, `backward` и `train`. В конце обучения сохраняет веса в `model.npz` и генерирует график `learning_curves`.
- `predict.py`: загружает `model.npz`, выполняет прямой проход на проверочных данных и выводит Ассигасу и значение BCE.

5 Результаты

При запуске обучения с архитектурой `[30, 16, 8, 2]`, скоростью обучения $\alpha = 0.1$ и 300 эпохами, модель демонстрирует быструю сходимость.

- Точность на проверочной выборке (Val Ассигасу) достигает $\approx 97 - 98\%$.
- Значение бинарной кросс-энтропии (BCE) стабилизируется на уровне $0.08 - 0.12$, что указывает на высокую уверенность модели в правильных предсказаниях.
- Графики кривых обучения (сохраняемые автоматически) не показывают признаков переобучения (train и val loss уменьшаются синхронно).

6 Заключение

В ходе выполнения проекта была успешно реализована архитектура многослойного персептрона без использования специализированных библиотек глубокого обучения. Были закреплены навыки работы с матричными операциями в NumPy, вычисления градиентов методом обратного распространения ошибки, а также проанализированы метрики качества классификации.